

# O geometriji diferencirane zasebnosti

---

Luka Lodrant

Mentor: doc. dr. Aljoša Peperko

17. april 2018

Fakulteta za matematiko in fiziko

Predstavitev problema

Priprava okolja

Končni rezultat

# Predstavitev problema

---

- Velike statistične podatkovne baze (big data)
- Primeri:
  - Google
  - Facebook
  - Državne statistike
- Zagotavljanje zasebnosti
- Politične težave
- Rešitev: anonimizacija podatkov

- Cynthia Dwork - 2006
- Frank McSherry, Kobbi Nissim in Adam D. Smith
  - objava podatkov brez zasebnih informacij je nemogoča
  - z majhnim številom poizvedb je bazo mogoče poustvariti
- matematični model za analizo zasebnosti
- definira zasebnost kot nekaj merljivega

# Priprava okolja

---

Ime	Opravil UNM kviz
Anica	0
Boštjan	1
Ciril	1
Domen	0
Ester	1

# Predstavitev podatkov

## Definicija

**Podatkovno bazo** predstavimo kot vektor v  $\mathbb{R}^n$

$$A = (0, 1, 1, 0, 1)$$

## Definicija

**Poizvedba** je linearna kombinacija členov v podatkovni bazi

$$p(A) = 1 * x_0 + 0 * x_1 + \dots$$

## Definicija

**Mehanizem zasebnosti** je naključen algoritem, ki kot vhodni podatek vzame podatkovno bazo in poizvedbo in vrne rezultat v obliki realnega števila.



## Definicija

Za  $\epsilon$ -zaseben mehanizem  $M$  in dve podatkovni bazi, ki se razlikujeta le v enem členu  $D1$  in  $D2$  velja:

$$Pr[M(D1) \in S] \leq \exp(\epsilon) \times Pr[M(D2) \in S]$$

kjer je  $S$  katerakoli podmnožica slike  $M$ .

## Problem

Vsak zasebnostni mehanizem povzroči napako v izhodnih podatkih. Ali je mogoče podati dobro spodnjo in zgornjo mejo te napake v odvisnosti od željene zasebnosti?

## Konční rezultat

---

Z uporabo geometrijskih lastnosti naše predstavitve podatkov lahko pridemo do sledeče spodnje meje.

### Izrek

Naj bo  $\epsilon > 0$  in  $F : \mathbb{R}^n \rightarrow \mathbb{R}^d$  linearna preslikava, ki predstavlja poizvedbo. Potem ima vsak  $\epsilon$ -zaseben mehanizem  $M$  napako v  $l_1$  normi vsaj  $\Omega(\min(d * \sqrt{d}/\epsilon, d\sqrt{\log(n/d)}/\epsilon))$